
MODELLO CALCISTICO

Danilo Buttu
353244
s353244@studenti.polito.it

Raffaele Vita
362747
s362747@studenti.polito.it

31 gennaio 2026

ABSTRACT

In questo elaborato si cercherà di rispondere ad una delle domande che più spesso intercorre nei pensieri degli amanti del gioco del calcio: quanto finirà la partita?

Tramite gli strumenti della statistica bayesiana andremo a creare dei modelli che ci permettono matematicamente di avere una stima dei risultati delle varie partite, considerando alcuni degli aspetti delle partite di calcio che abbiamo ritenuto più rilevanti per creare un modello ragionevole.

In particolare la nostra analisi evolverà secondo due modelli:

1. Un modello gerarchico che parte da un modello lineare generalizzato (GLM) per poi arricchirlo tramite delle scelte modellistiche che auspicabilmente cattureranno buona parte della varianza del nostro caso studio
2. Un modello mistura che arricchisce ulteriormente il modello precedente, supponendo che alla base del fenomeno preso in esame ci sia un processo latente, modellizzato con un Hidden Markov Model (HMM), che permetta di tener conto dello stato di forma che le società calcistiche attraversano durante la stagione

Indice

1	Descrizione del dataset	3
2	Modello 1	3
2.1	Notazioni e ragionamenti preliminari sul modello 1	3
2.2	Descrizione del modello 1	4
2.3	Full Conditional del modello 1	5
2.4	Analisi dei risultati dell'MCMC	7
2.5	Ranking tramite modello 1	9
3	Modello 2	10
3.1	Notazioni e ragionamenti preliminari sul modello 2	10
3.2	Descrizione del modello 2	11
3.3	full conditional del modello 2	11
3.4	Analisi dei risultati dell'MCMC	15
3.5	Ranking tramite modello 2	20
3.6	Predizione dei risultati	21
3.7	Elaborazione dei campioni predittivi	22
3.8	Analisi della predizione della partita Arsenal VS Chelsea	23
4	Conclusioni	23
4.1	Evoluzione modellistica e Stato di Forma	23
4.2	Il Fattore Casa	23
4.3	Capacità Predittiva e Ranking	24
4.4	Sviluppi Futuri	24
5	R scripts	24
5.1	Dove trovare il codice usato per le simulazioni?	24

1 Descrizione del dataset

Come qualsiasi modello statistico, il primo passo è quello della raccolta dei dati, che successivamente utilizzeremo per addestrare i nostri due modelli. L'insieme dei nostri dati, che da ora in poi chiameremo Dataset, raccoglie tutte le partite della massima serie Inglese (Premier League) che si sono svolte nella stagione 2015/16, che ha visto trionfare inaspettatamente il Leicester City guidato da 'Sir' Claudio Ranieri. Questo Dataset contiene diversi dati per ogni partita, questi dati sono raccolti in un unico file CSV composto nel seguente modo :

1. La data in cui è stata giocata
2. Il nome della squadra di casa
3. Il risultato finale della partita
4. Il nome della squadra in trasferta

Il Dataset in questione è un estratto di un Dataset pubblico molto più ampio, che è disponibile su Github.

Tabella 1: Esempio del Dataset per la prima giornata

Date	Home Team	Score	Away Team
Sat Aug 8 2015	Manchester United	1-0	Tottenham Hotspur
Sat Aug 8 2015	AFC Bournemouth	0-1	Aston Villa
Sat Aug 8 2015	Everton	2-2	Watford
Sat Aug 8 2015	Leicester City	4-2	Sunderland
Sat Aug 8 2015	Chelsea	2-2	Swansea City
Sat Aug 8 2015	Norwich City	1-3	Crystal Palace
Sun Aug 9 2015	Arsenal	0-2	West Ham United
Sun Aug 9 2015	Newcastle United	2-2	Southampton
Sun Aug 9 2015	Stoke City	0-1	Liverpool
Mon Aug 10 2015	West Bromwich Albion	0-3	Manchester City

2 Modello 1

2.1 Notazioni e ragionamenti preliminari sul modello 1

Prima di introdurre il modello 1, al quale d'ora in poi ci riferiremo con (M1), andiamo a definire i vari elementi che compariranno nel modello:

- G : insieme delle partite della stagione analizzata
- T : insieme delle squadre presenti nella stagione analizzata
- $h : G \rightarrow T$: funzione che ci permette di identificare univocamente la squadra che gioca in casa
- $a : G \rightarrow T$: funzione che ci permette di identificare univocamente la squadra che gioca in trasferta

Se per esempio abbiamo $g = (\text{Manchester City} - \text{Chelsea}) \in G \implies h(g) = \text{Manchester City}$, $a(g) = \text{Chelsea}$

- y_{g1}, y_{g2} : gol segnati rispettivamente dalla squadra di casa e dalla squadra ospite nella partita $g \in G$
- $home$: fattore casa (assunto identico per ognuna delle squadre)
- att_t : fattore di attacco della squadra $t \in T$
- def_t : fattore di difesa della squadra $t \in T$

Ora possiamo dunque indicare in maniera formale il risultato di una partita come $\mathbf{y}_g = (y_{g1}, y_{g2})^T$ e supponiamo che y_{g1} e y_{g2} siano due variabili aleatorie indipendenti distribuite come una *Poisson*, ognuna avente il proprio rate.

2.2 Descrizione del modello 1

$$\begin{aligned}
y_{gi} \mid \lambda_{gi} &\sim \text{Poisson}(\lambda_{gi}) \quad \forall g \in G, \quad i = 1, 2 \\
\eta_{g1} = \log(\lambda_{g1}) &= \text{home} + \text{att}_{h(g)} + \text{def}_{a(g)} \quad \forall g \in G \\
\eta_{g2} = \log(\lambda_{g2}) &= \text{att}_{a(g)} + \text{def}_{h(g)} \quad \forall g \in G \\
\text{home} &\sim N(0, \sigma_{\text{home}}^2) \\
\text{att}_t &\sim N(\mu_{\text{att}}, \tau_{\text{att}}^2) \quad \forall t \in T \\
\text{def}_t &\sim N(\mu_{\text{def}}, \tau_{\text{def}}^2) \quad \forall t \in T \\
\mu_{\text{att}}, \mu_{\text{def}} &\sim N(0, \sigma^2) \\
\tau_{\text{att}}^2, \tau_{\text{def}}^2 &\sim \text{IG}(a, b)
\end{aligned}$$

dove $\sigma_{\text{home}}^2, \sigma^2, a, b$ sono scelti in modo tale da avere delle Prior debolmente informative sui parametri (ad esempio le varianze delle normali dovranno essere dei numeri grandi in modo tale da "appiattire" la distribuzione normale a priori). Il modello così definito non è identificabile, poiché i fattori di attacco e difesa compaiono come somma quando modelliamo η_{gi} , per ovviare a questo problema imponiamo i seguenti vincoli:

$$\sum_{t \in T} \text{att}_t = 0, \quad \sum_{t \in T} \text{def}_t = 0$$

che sono ragionevoli, ma cambiano l'interpretazione dei fattori di attacco e difesa, che adesso dovranno essere pensati come fattori rispetto alla media del campionato. Ovvero, se per una squadra $t \in T$ abbiamo che $\text{att}_t = 1.5$, questo vuol dire che la squadra ha un attacco 1.5 volte superiore rispetto alla media del campionato (analogo per il fattore di difesa).

Per farci un'idea più chiara di questo primo modello possiamo creare un DAG che ci permette di visualizzare come i vari parametri si relazionano l'un l'altro.




Figura 1: DAG del modello 1

In questo caso abbiamo scelto di considerare la singola partita in modo da rendere il tutto più leggibile, con $\text{att}_h, \text{att}_a$ a rappresentare rispettivamente il coefficiente di attacco della squadra in casa e in trasferta, similmente utilizziamo lo stesso approccio per $\text{def}_h, \text{def}_a$.

Notiamo che nel primo livello di questo DAG troviamo i vari Iper-Parametri che andranno a definire le distribuzioni di cui ricaveremo successivamente i parametri per le singole squadre.

Da notare che a differenza dei vari μ e τ^2 il parametro σ^2 per home è uguale per tutte le partite, poiché abbiamo deciso di modellarlo come un fattore unico per tutte le squadre.

2.3 Full Conditional del modello 1

Come primo passo andiamo a calcolarci la congiunta del nostro modello:

$$\begin{aligned}
 f(\mathbf{y}, \theta) = & \underbrace{\prod_{g=1}^G Pois(y_{g,1} | \exp(\eta_{g,1})) Pois(y_{g,2} | \exp(\eta_{g,2}))}_{\text{likelihood}} \\
 & \times \underbrace{\prod_{t=1}^T N(att_t | \mu_{att}, \tau_{att}^2) N(def_t | \mu_{def}, \tau_{def}^2)}_{\text{fattori di attacco e difesa}} \times \underbrace{N(home | 0, \sigma_{home}^2)}_{\text{effetto casa}} \\
 & \times \underbrace{N(\mu_{att} | 0, \sigma^2) IG(\tau_{att}^2 | a, b)}_{\text{prior iperparametri per fattori d'attacco}} \times \underbrace{N(\mu_{def} | 0, \sigma^2) IG(\tau_{def}^2 | a, b)}_{\text{prior iperparametri per fattori di difesa}}
 \end{aligned} \tag{1}$$

Calcoliamo ora le varie Full Conditional utilizzando il Kernel-Trick in modo da provare a riconoscere qualche legge nota e ottenere di conseguenza delle forme chiuse per le distribuzioni

- $\mu_{att} | \dots$

$$\begin{aligned}
 f(\mu_{att} | \dots) & \propto f(\mathbf{y}, \mathbf{z}, \theta) \\
 & \propto N(\mu_{att} | 0, \sigma^2) \times \prod_{t=1}^T N(att_t | \mu_{att}, \tau_{att}^2) \\
 & \propto \exp\left(-\frac{\mu_{att}^2}{2\sigma^2}\right) \times \exp\left(-\frac{(att_t - \mu_{att})^2}{2\tau_{att}^2}\right) \\
 & \propto \exp\left[-\frac{\mu_{att}^2}{2\sigma^2} - \sum_{t=1}^T \frac{(att_t - \mu_{att})^2}{2\tau_{att}^2}\right] \\
 & \propto \exp\left[\frac{1}{2}\mu_{att}^2 \left(\frac{1}{\sigma^2} + \frac{T}{\tau_{att}^2}\right) - \mu_{att} \left(\frac{\sum_{t=1}^T att_t}{\tau_{att}^2}\right)\right]
 \end{aligned}$$

Riconosciamo il kernel di una Normale Univariata, ciò ci permette di utilizzare il Gibbs Sampler per il nostro Algoritmo.

$$\Rightarrow \mu_{att} | \dots \sim N\left(\left(\frac{1}{\sigma^2} + \frac{T}{\tau_{att}^2}\right)^{-1} \left(\frac{\sum_{t=1}^T att_t}{\tau_{att}^2}\right), \left(\frac{1}{\sigma^2} + \frac{T}{\tau_{att}^2}\right)^{-1}\right)$$

- $\mu_{def} | \dots$

In questo caso notiamo la simmetria fra μ_{att} e μ_{def} , ciò ci permette di evitare di rifare i calcoli e dedurre

$$\text{direttamente che: } \mu_{def} | \dots \sim N\left(\left(\frac{1}{\sigma^2} + \frac{T}{\tau_{def}^2}\right)^{-1} \left(\frac{\sum_{t=1}^T def_t}{\tau_{def}^2}\right), \left(\frac{1}{\sigma^2} + \frac{T}{\tau_{def}^2}\right)^{-1}\right)$$

- $\tau_{att}^2 | \dots$

$$\begin{aligned}
 f(\tau_{att}^2 | \dots) & \propto f(\mathbf{y}, \theta) \\
 & \propto IG(\tau_{att}^2 | a, b) \times \prod_{t=1}^T N(att_t | \mu_{att}, \tau_{att}^2) \\
 & \propto (\tau_{att}^2)^{-a-1} \exp(-b/\tau_{att}^2) \times (\tau_{att}^2)^{-T/2} \exp\left(-\sum_{t=1}^T \frac{(att_t - \mu_{att})^2}{2\tau_{att}^2}\right) \\
 & \propto (\tau_{att}^2)^{-(a+T/2)-1} \exp\left[\frac{1}{\tau_{att}^2} \left(b + \frac{1}{2} \sum_{t=1}^T (att_t - \mu_{att})^2\right)\right]
 \end{aligned}$$

Riconosciamo il Kernel di una Inverse Gamma con determinati parametri.

$$\Rightarrow \tau_{att}^2 | \dots \sim IG\left(a + T/2, b + \frac{1}{2} \sum_{t=1}^T (att_t - \mu_{att})^2\right)$$

- $\tau_{def}^2 \mid \dots$

Utilizziamo anche in questo caso la simmetria dei fattori di difesa e d'attacco.

$$\implies \tau_{def}^2 \mid \dots \sim IG\left(a + T/2, b + \frac{1}{2} \sum_{t=1}^T (def_t - \mu_{def})^2\right)$$

- $att_t \mid \dots$

Definiamo i seguenti insiemi che ci torneranno utili nella determinazione della Full Conditional:

$$\begin{aligned} A_t^{home} &= \{g \in G : h(g) = t\} \\ A_t^{away} &= \{g \in G : a(g) = t\} \end{aligned}$$

$$\begin{aligned} f(att_t \mid \dots) &\propto f(\mathbf{y}, \mathbf{z}, \theta) \propto N(att_t \mid \mu_{att}, \tau_{att}^2) \times \underbrace{f(\mathbf{y} \mid att_t, \dots)}_{\text{termine di likelihood}} \\ &\propto \exp\left(-\frac{(att_t - \mu_{att})^2}{2\tau_{att}^2}\right) \times f(\mathbf{y} \mid att_t, \dots) \\ &\propto \exp\left(-\frac{(att_t - \mu_{att})^2}{2\tau_{att}^2}\right) \times \underbrace{\prod_{g \in A_t^{home}} \exp[y_{g,1}(home + att_t + \overbrace{def_{a(g)}}^{:=d_g}) - \exp(home + att_t + d_g)]}_{\text{likelihood per gol in casa}} \\ &\quad \times \underbrace{\prod_{g \in A_t^{away}} \exp[y_{g,2}(att_t + \overbrace{def_{h(g)}}^{:=d'_g}) - \exp(att_t + d'_g)]}_{\text{likelihood per gol in trasferta}} \end{aligned}$$

In questo caso non si riconosce una forma chiusa per questa distribuzione, di conseguenza dobbiamo utilizzare un passo Metropolis per campionare da questa distribuzione

$$\begin{aligned} \implies f(att_t \mid \dots) &\propto \exp\left(-\frac{(att_t - \mu_{att})^2}{2\tau_{att}^2}\right) \times \prod_{g \in A_t^{away}} \exp[y_{g,2}(att_t + d'_g) - \exp(att_t + d'_g)] \\ &\quad \times \prod_{g \in A_t^{home}} \exp[y_{g,1}(home + att_t + d_g) - \exp(home + att_t + d_g)] \end{aligned}$$

dove $d_g = def_{a(g)}$ e $d'_g = def_{h(g)}$.

- $def_t \mid \dots$

Come fatto in precedenza notiamo la simmetria con att_t in modo da riutilizzare alcuni dei risultati precedenti. Definiamo quindi i seguenti oggetti:

$$a_g = att_{a(g)}, \quad a'_g = att_{h(g)}$$

Data quindi l'evidente simmetria con att_t la Full Conditional cercata è:

$$\begin{aligned} f(def_t \mid \dots) &\propto \exp\left(-\frac{(def_t - \mu_{def})^2}{2\tau_{def}^2}\right) \times \prod_{g \in A_t^{away}} \exp[y_{g,2}(a_g + def_t) - \exp(a_g + def_t)] \\ &\quad \times \prod_{g \in A_t^{home}} \exp[y_{g,1}(home + a'_g + def_t) - \exp(home + a'_g + def_t)] \end{aligned}$$

Visto che non si riconosce una Distribuzione nota dobbiamo nuovamente utilizzare un passo Metropolis per campionare

• $home \mid \dots$

$$f(home \mid \dots) \propto f(\mathbf{y}, \theta) \propto N(home \mid 0, \sigma^2) f(\mathbf{y} \mid home, \dots) \\ \propto \exp\left(-\frac{home^2}{2\sigma^2}\right) \times \prod_{g=1}^G \exp[y_{g,1}(home + a_g + d_g) - \exp(home + a_g + d_g)]$$

dove a_g e d_g sono le quantità definite precedentemente.

$$\Rightarrow f(home \mid \dots) \propto \exp\left(-\frac{home^2}{2\sigma^2}\right) \times \prod_{g=1}^G \exp[y_{g,1}(home + a_g + d_g) - \exp(home + a_g + d_g)]$$

Neanche in questo caso abbiamo ottenuto una forma chiusa per la full conditional.

2.4 Analisi dei risultati dell'MCMC

Utilizzando i risultati ottenuti precedentemente abbiamo implementato in R una funzione che permette di eseguire l'algoritmo MCMC relativo al modello (M1), tale funzione ha bisogno per lavorare un dataset, non necessariamente completo. Infatti anche se le diamo come dataset l'elenco dei risultati di una stagione ancora non conclusa il nostro software sarà capace di stimare i fattori con i dati disponibili. I risultati che andremo ad analizzare sono ottenuti eseguendo il codice per 50000 Iterazioni, successivamente andremo ad effettuare un Burn-in di 10000 Iterazioni e un Thin di parametro uguale a 10 ottenendo così 4000 campioni effettivi.

Osserviamo ora i trace plot ottenuti dei parametri Home, att e def




Figura 2: Parametri d'attacco e difesa a confronto

Si può notare che le varie catene non mostrano 'Trend' e quindi si distribuiscono intorno un valore medio, anche la funzione di Auto-Correlazione mostra che per entrambi i parametri delle medie sono scorrelate rispetto ai precedenti passi, mentre per i parametri delle varianze, l'ACF assume valore quasi nullo per le iterazioni di distanza maggiore di 5. Dunque il nostro modello stima che : $\hat{\mu}_{att} = 0.0073$, $\hat{\mu}_{def} = 0.008$, $(\hat{\sigma}_{att}^2) = 0.081$, $(\hat{\sigma}_{def}^2) = 0.062$




Figura 3: Distribuzione e Trace Plot Effetto casa

Analizziamo la catena dell'effetto "Casa" e la sua distribuzione. Questo parametro modella il vantaggio che una squadra ha quando gioca in casa, che in questo modello è supposto identico per tutte le squadre. Notiamo che il trace plot sembra suggerire che il nostro algoritmo sia arrivato a convergenza, quindi calcoliamo la stima del parametro e verifichiamo, utilizzando l'intervallo di credibilità al 95%, se questo effetto è statisticamente presente. $\hat{home} = 0.332, IG(home) = [0.243, 0.427]$

Osservato che $0 \notin IG(home)$ possiamo affermare che statisticamente la squadra che gioca in casa ha un effettivo vantaggio, dovuto magari al campo, tifo o qualsivoglia caratteristica reale modellizzata da questo parametro.

Osserviamo le stime dei parametri d'Attacco e di difesa di tutte le squadre contenute nel dataset




Figura 4: Parametri d'attacco e difesa a confronto

Queste stime rappresentano quanto le squadre difendono/attaccano bene rispetto alla media del campionato, ciò è dovuto al fatto che abbiamo imposto il vincolo di identificabilità $\sum_{t \in T} att_t = 0, \sum_{t \in T} def_t = 0$.

Tenendo in mente ciò osserviamo che il migliore attacco è quello del Manchester City, visto che si osserva il valore positivo maggiore, ciò rappresenta accuratamente i risultati della squadra in quella stagione che ha effettivamente segnato 71 gol complessivi, più di chiunque altro quel anno.

Per quanto riguarda la difesa invece i valori ottimali sono quelli negativi di modulo maggiore, infatti ciò ci indica che la squadra in questione riesce a impedire al team avversario di conquistare il punto in modo efficace.

Confrontando i parametri stimati con i gol subiti in quel anno notiamo che, in effetti, le due squadre con def più basso sono Manchester United e Tottenham Hotspur che hanno subito entrambe solo 35 Gol.

Analizziamo allora il trace plot per i parametri att e def del Manchester City in modo da verificare se il nostro algoritmo converge, similmente si possono ottenere i grafici per tutte le squadre per onere di sintesi eviteremo in questa sede di aggiungerli.




Figura 5: Trace plot e ACF per attacco e difesa del MCI

Osserviamo che non si notano trend ne valori anomali e frequenti nel trace plot, ciò ci indica una buona convergenza per entrambe le stime.

Anche per quanto riguarda l'ACF notiamo che decresce molto rapidamente per sia la difesa che per l'attacco.

2.5 Ranking tramite modello 1

Attraverso questi parametri stimati possiamo creare una semplice metrica che ci indica quale di queste squadre vince di più, in teoria la squadra ottimale è quella che segna più di tutte e ne subisce il meno possibile ma ciò difficilmente succede nella vita reale. Per questo utilizziamo la formula $OverallScore_t = att_t - def_t \quad \forall t \in T$ che ci permette di capire quanto il nostro algoritmo reputi una squadra sia buona e di conseguenza classificarla.

Tabella 2: Confronto Classifica 2015/16: Modello vs Realtà

Team	Attacco	Difesa	Overall	Pos Vera	Diff
Tottenham Hotspur	0.2667	-0.2432	0.5099	3	+2
Leicester City	0.2498	-0.2303	0.4801	1	-1
Arsenal	0.2135	-0.2308	0.4443	2	-1
Manchester City	0.2888	-0.1415	0.4303	4	0
Southampton	0.1310	-0.1478	0.2788	6	+1
Manchester United	-0.0278	-0.2623	0.2345	5	-1
West Ham United	0.2169	0.0128	0.2042	7	0
Liverpool	0.1892	0.0004	0.1888	8	0
Chelsea	0.1367	0.0420	0.0948	10	+1
Everton	0.1368	0.0696	0.0672	11	+1
Watford	-0.1776	-0.0171	-0.1604	13	+2
Swansea City	-0.1460	0.0209	-0.1669	12	0
Crystal Palace	-0.1941	0.0012	-0.1953	15	+2
Sunderland	-0.0335	0.1624	-0.1959	17	+3
Stoke City	-0.1571	0.0600	-0.2171	9	-6
West Bromwich Albion	-0.2949	-0.0489	-0.2460	14	-2
Newcastle United	-0.1010	0.1939	-0.2949	18	+1
AFC Bournemouth	-0.0776	0.2210	-0.2986	16	-2
Norwich City	-0.1872	0.2178	-0.4050	19	0
Aston Villa	-0.4329	0.3199	-0.7528	20	0

Dal confronto della classifica così ottenuta con la reale classifica di quel anno notiamo come le squadre in fondo alla classifica, Norwich e Aston Villa, vengono accuratamente descritte mentre altre come lo Stoke City vengono sottostimate (oppure hanno avuto un periodo di over-performance) o come il Tottenham sovrastimate.

3 Modello 2

3.1 Notazioni e ragionamenti preliminari sul modello 2

Un ipotesi modellistica ragionevole se si vuole stimare i gol segnati dalle squadre di calcio nelle partite e conseguentemente anche i risultati di quest'ultime è sicuramente quella di considerare un fattore che modelli lo stato di forma delle squadre. Infatti durante una stagione calcistica le squadre alternano dei periodi in cui i giocatori sono athleticamente performanti, all'interno dello spogliatoio l'atmosfera è rilassata ed i risultati generalmente sono positivi, in maniera duale, essendo impossibile per una squadra mantenere per tutte le partite una stato di forma elevato, arrivano anche i periodi in cui una squadra "non è in forma" e conseguentemente si fa più fatica a giocare, i giocatori sono stanchi e le performance calano. E' lecito inoltre supporre che se una squadra è in forma, molto probabilmente lo sarà anche nella partita successiva (analogo se la squadra non è in forma).

A partire da queste considerazioni possiamo espandere (M1) aggiungendo un'ulteriore elemento di complessità che ci permetta di modellare lo stato di forma della squadra, ovvero una variabile latente

- $z_{ts} \in \{1, 2\}$: stato di forma della squadra t durante la sua s -esima partita

dove $z_{ts} = 1$ se la squadra è "in forma" e $z_{ts} = 2$ se la squadra "non è in forma". Oltre agli insiemi e alle funzioni ausiliarie definite per il modello (M1), abbiamo adesso bisogno di introdurre dei nuovi elementi:

- S_t : insieme delle partite giocate dalla squadra t (in ordine cronologico)
- $s_{h(g)} \in S_{h(g)}$, $s_{a(g)} \in S_{a(g)}$: indice della partita s -esima rispettivamente per la squadra di casa e ospite (in ordine cronologico)
- att_{tk} , def_{tk} : fattore rispettivamente di attacco e difesa per la squadra $t \in T$ quando si trova nello stato $k = 1, 2$
- $\mu_{att}^{(k)}$, $\mu_{def}^{(k)}$: media della normale che genera rispettivamente le att_{tk} , def_{tk}
- $(\tau_{att}^2)^{(k)}$, $(\tau_{def}^2)^{(k)}$: varianza della normale che genera rispettivamente le att_{tk} , def_{tk}

- P : matrice di transizione del processo latente $P_{ij} = P(z_{t,s} = j | z_{t,s-1} = i)$ (nel nostro caso avendo supposto $L = 2$ stati avremo una matrice 2x2)
- $\pi = P(z_{t,1} = k)$: distribuzione degli stati iniziali, ovvero lo stato di forma che ogni squadra ha nella partita d'esordio (è sostanzialmente il dato iniziale della Markov chain)

3.2 Descrizione del modello 2

$$\begin{aligned}
y_{gi} &| \lambda_{gi} \sim \text{Poisson}(\lambda_{gi}) \quad \forall g \in G, \quad i = 1, 2 \\
\eta_{g1} &= \log(\lambda_{g1}) = \text{home} + \text{att}_{h(g), z_{h(g), s_{h(g)}}} + \text{def}_{a(g), z_{a(g), s_{a(g)}}} \quad \forall g \in G \\
\eta_{g2} &= \log(\lambda_{g2}) = \text{att}_{a(g), z_{a(g), s_{a(g)}}} + \text{def}_{h(g), z_{h(g), s_{h(g)}}} \quad \forall g \in G \\
z_{t,s} | z_{t,s-1} &\sim \text{Discrete}(P_{z_{t,s-1}, \cdot}) \quad \forall t \in T \text{ dove } P_{i,\cdot} \text{ è la riga } i\text{-esima di } P \\
\text{att}_{t,k} &\sim N(\mu_{\text{att}}^{(k)}, (\tau_{\text{att}}^2)^{(k)}) \quad \forall t \in T, \quad k = 1, 2 \\
\text{def}_{t,k} &\sim N(\mu_{\text{def}}^{(k)}, (\tau_{\text{def}}^2)^{(k)}) \quad \forall t \in T, \quad k = 1, 2 \\
\mu_{\text{att}}^{(k)}, \mu_{\text{def}}^{(k)} &\sim N(0, \sigma^2) \quad k = 1, 2 \\
(\tau_{\text{att}}^2)^{(k)}, (\tau_{\text{def}}^2)^{(k)} &\sim \text{IG}(a, b) \quad k = 1, 2 \\
z_{t,1} &\sim \text{Discrete}(\pi) \quad \forall t \in T \\
\pi &\sim \text{Dirichlet}(1, 1) \\
P_{i,\cdot} &\sim \text{Dirichlet}(1, 1) \quad i = 1, 2
\end{aligned}$$

Osserviamo come con l'introduzione dello stato di forma delle squadre nel modello, abbiamo aumentato la complessità di quest'ultimo e per questo motivo da qui in avanti si userà una notazione che ci permetta di semplificare la comprensione di determinati passaggi come ad esempio indicare la densità di probabilità di una variabile aleatoria con la sua distribuzione (ad esempio se $X \sim \text{Poisson}(\lambda) \implies f(x|\lambda) = \text{Pois}(x|\lambda)$)

3.3 full conditional del modello 2

In questa nuova versione del modello non rappresentiamo tramite DAG la densità congiunta come fatto per (M1), poichè il grafo risulterebbe eccessivamente denso in termine di archi. Possiamo però scrivere direttamente la densità congiunta del modello in maniera estesa.

Siano $\mathbf{y} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_G)^T$, $\mathbf{z} = (z_{1,1}, \dots, z_{T,1}, z_{1,2}, \dots, z_{T,2}, \dots, z_{T,G})^T$ e θ il vettore che contiene tutti i parametri del modello.

Possiamo adesso scrivere la congiunta come:

$$\begin{aligned}
f(\mathbf{y}, \mathbf{z}, \theta) &= \underbrace{\prod_{g=1}^G \text{Pois}(y_{g,1} | \exp(\eta_{g,1})) \text{Pois}(y_{g,2} | \exp(\eta_{g,2}))}_{\text{likelihood}} \times \underbrace{\prod_{t=1}^T [\text{Disc}(z_{t,1} | \pi) \prod_{s=2}^{S_t} \text{Disc}(z_{t,s} | P_{z_{t,s-1}, \cdot})]}_{\text{effetto del modello mistura (HMM)}} \\
&\times \underbrace{\prod_{t=1}^T \prod_{k=1}^2 N(\text{att}_{t,k} | \mu_{\text{att}}^{(k)}, (\tau_{\text{att}}^2)^{(k)}) N(\text{def}_{t,k} | \mu_{\text{def}}^{(k)}, (\tau_{\text{def}}^2)^{(k)})}_{\text{fattori di attacco e difesa}} \times \underbrace{N(\text{home} | 0, \sigma^2)}_{\text{effetto casa}} \\
&\times \underbrace{\prod_{k=1}^2 N(\mu_{\text{att}}^{(k)} | 0, \sigma^2) \text{IG}((\tau_{\text{att}}^2)^{(k)} | a, b)}_{\text{prior iperparametri per fattori d'attacco}} \times \underbrace{\prod_{k=1}^2 N(\mu_{\text{def}}^{(k)} | 0, \sigma^2) \text{IG}((\tau_{\text{def}}^2)^{(k)} | a, b)}_{\text{prior iperparametri per fattori di difesa}} \\
&\times \underbrace{\text{Dir}(\pi | 1, 1,) \prod_{i=1}^2 \text{Dir}(P_{i,\cdot} | 1, 1)}_{\text{prior del modello mistura (HMM)}}
\end{aligned}$$

Possiamo adesso finalmente determinare le full conditional, sfruttando la proporzionalità di quest'ultime con la densità congiunta del modello.

- $z_{t,s} \mid \dots$

Indichiamo per un generico vettore v il vettore privato dell'elemento i -esimo con v_{-i} .

$$P(z_{t,s} = k \mid \dots) \propto f(\mathbf{y}, \mathbf{z}, \theta) \propto \underbrace{f(z_{t,s} \mid \mathbf{z}_{-(z_{t,s})})}_{\text{termini di transizione}} \times \underbrace{f(\mathbf{y} \mid z_{t,s} = k, \dots)}_{\text{termini di likelihood}} \stackrel{:= L_t(s,k)}{}$$

Andiamo adesso a studiare separatamente i termini che compaiono nella full conditional:

1. Termini di transizione

- Se $s = 1$ (partita d'esordio) $\implies Disc(z_{t,1} \mid \pi) \times Disc(z_{t,2} \mid P_{z_{t,1}, \cdot})$
- Se $1 < s < S_t \implies Disc(z_{t,s} \mid P_{z_{t,s-1}, \cdot}) \times Disc(z_{t,s+1} \mid P_{z_{t,s}, \cdot})$
- Se $s = S_t \implies Disc(z_{t,s} \mid P_{z_{t,s-1}, \cdot})$

2. Termini di likelihood

Sia g la partita in cui la squadra t gioca la sua s -esima partita.

- Se t è in casa, ovvero $h(g) = t$, allora:
 $\eta_{g,1} = home + att_{t,z_{t,s}} + def_{a(g),z_{a(g)},s_{a(g)}}$
 $\eta_{g,2} = att_{a(g),z_{a(g)},s_{a(g)}} + def_{t,z_{t,s}}$
 $\implies L_t(s, k) = Pois(y_{g,1} \mid exp(\eta_{g,1}(z_{t,s} = k))) \times Pois(y_{g,2} \mid exp(\eta_{g,2}(z_{t,s} = k)))$
- Se t è in trasferta, ovvero $a(g) = t$, allora:
 $\eta'_{g,1} = home + att_{h(g),z_{h(g)},s_{h(g)}} + def_{t,z_{t,s}}$
 $\eta'_{g,2} = att_{t,z_{t,s}} + def_{h(g),z_{h(g)},s_{h(g)}}$
 $\implies L_t(s, k) = Pois(y_{g,1} \mid exp(\eta'_{g,1}(z_{t,s} = k))) \times Pois(y_{g,2} \mid exp(\eta'_{g,2}(z_{t,s} = k)))$

Mettendo insieme le considerazioni appena fatte otteniamo la full conditional per $z_{t,s}$ (non normalizzata per

$$\text{avere una notazione compatta}) P(z_{t,s} = k) \propto \begin{cases} \pi_k \cdot P_{k,z_{t,2}} \cdot L_t(1, k) & \text{se } s = 1 \\ P_{z_{t,s-1},k} \cdot P_{k,z_{t,s+1}} \cdot L_t(s, k) & \text{se } 1 < s < S_t \\ P_{z_{t,s-1},k} \cdot L_t(s, k) & \text{se } s = S_t \end{cases}$$

- $att_{t,k} \mid \dots$

Definiamo i seguenti insiemi che ci torneranno utili nella determinazione della full conditional:

$$A_{t,k}^{home} = \{g \in G : h(g) = t, z_{t,s_{h(g)}} = k\}$$

$$A_{t,k}^{away} = \{g \in G : a(g) = t, z_{t,s_{a(g)}} = k\}$$

$$\begin{aligned} f(att_{t,k} \mid \dots) &\propto f(\mathbf{y}, \mathbf{z}, \theta) \propto N(att_{t,k} \mid \mu_{att}^{(k)}, (\tau_{att}^2)^{(k)}) \times \underbrace{f(\mathbf{y} \mid att_{t,k}, \dots)}_{\text{termine di likelihood}} \\ &\propto exp\left(-\frac{(att_{t,k} - \mu_{att}^{(k)})^2}{2(\tau_{att}^2)^{(k)}}\right) \times f(\mathbf{y} \mid att_{t,k}, \dots) \\ &\propto exp\left(-\frac{(att_{t,k} - \mu_{att}^{(k)})^2}{2(\tau_{att}^2)^{(k)}}\right) \times \underbrace{\prod_{g \in A_{t,k}^{home}} exp[y_{g,1}(home + att_{t,k} + \overbrace{def_{a(g),z_{a(g)},s_{a(g)}}}^{:=d_g}) - exp(home + att_{t,k} + d_g)]}_{\text{likelihood per gol in casa}} \\ &\quad \times \underbrace{\prod_{g \in A_{t,k}^{away}} exp[y_{g,2}(att_{t,k} + \overbrace{def_{h(g),z_{h(g)},s_{h(g)}}}^{:=d'_g}) - exp(att_{t,k} + d'_g)]}_{\text{likelihood per gol in trasferta}} \end{aligned}$$

Non si riesce a trovare una forma chiusa per questa full conditional perciò dovremmo usare un passo Metropolis nell'MCMC per campionare da questa distribuzione.

$$\implies f(att_{t,k} \mid \dots) \propto exp\left(-\frac{(att_{t,k} - \mu_{att}^{(k)})^2}{2(\tau_{att}^2)^{(k)}}\right) \times \prod_{g \in A_{t,k}^{away}} exp[y_{g,2}(att_{t,k} + d'_g) - exp(att_{t,k} + d'_g)]$$

$$\times \prod_{g \in A_{t,k}^{home}} \exp[y_{g,1}(home + att_{t,k} + d_g) - \exp(home + att_{t,k} + d_g)]$$

dove $d_g = def_{a(g), z_{a(g)}, s_{a(g)}}$ e $d'_g = def_{h(g), z_{h(g)}, s_{h(g)}}$

- $def_{t,k} \mid \dots$

Per calcolare la full conditional del fattore di difesa possiamo riutilizzare parte dei risultati che abbiamo già determinato in precedenza, facendo appello al ragionamento applicato per studiare le full conditional del fattore d'attacco. Definiamo quindi i seguenti oggetti:

$$a_g = att_{a(g), z_{a(g)}, s_{a(g)}}, a'_g = att_{h(g), z_{h(g)}, s_{h(g)}}$$

Data l'evidente simmetria dei calcoli già svolti per $att_{t,k}$ la full conditional cercata è:

$$f(def_{t,k} \mid \dots) \propto \exp\left(-\frac{def_{t,k} - \mu_{def}^{(k)}{}^2}{2(\tau_{def}^2)^{(k)}}\right) \times \prod_{g \in A_{t,k}^{away}} \exp[y_{g,2}(a_g + def_{t,k}) - \exp(a_g + def_{t,k})]$$

$$\times \prod_{g \in A_{t,k}^{home}} \exp[y_{g,1}(home + a'_g + def_{t,k}) - \exp(home + a'_g + def_{t,k})]$$

Anche in questo caso non abbiamo una forma chiusa, perciò dovremmo utilizzare un Metropolis per campionare.

- $home \mid \dots$

$$f(home \mid \dots) \propto f(\mathbf{y}, \mathbf{z}, \theta) \propto N(home \mid 0, \sigma^2) f(\mathbf{y} \mid home, \dots)$$

$$\propto \exp\left(-\frac{home^2}{2\sigma^2}\right) \times \prod_{g=1}^G \exp[y_{g,1}(home + a_g + d_g) - \exp(home + a_g + d_g)]$$

dove a_g e d_g sono le quantità definite precedentemente.

$$\implies f(home \mid \dots) \propto \exp\left(-\frac{home^2}{2\sigma^2}\right) \times \prod_{g=1}^G \exp[y_{g,1}(home + a_g + d_g) - \exp(home + a_g + d_g)]$$

Neanche in questo caso abbiamo ottenuto una forma chiusa per la full conditional.

- $\mu_{att}^{(k)} \mid \dots$

$$f(\mu_{att}^{(k)} \mid \dots) \propto f(\mathbf{y}, \mathbf{z}, \theta)$$

$$\propto N(\mu_{att}^{(k)} \mid 0, \sigma^2) \times \prod_{t=1}^T N(att_{t,k} \mid \mu_{att}^{(k)}, (\tau_{att}^2)^{(k)})$$

$$\propto \exp\left(-\frac{(\mu_{att}^{(k)})^2}{2\sigma^2}\right) \times \exp\left(-\frac{(att_{t,k} - \mu_{att}^{(k)})^2}{2(\tau_{att}^2)^{(k)}}\right)$$

$$\propto \exp\left[-\frac{(\mu_{att}^{(k)})^2}{2\sigma^2} - \sum_{t=1}^T \frac{(att_{t,k} - \mu_{att}^{(k)})^2}{2(\tau_{att}^2)^{(k)}}\right]$$

$$\propto \exp\left[\frac{1}{2}(\mu_{att}^{(k)})^2\left(\frac{1}{\sigma^2} + \frac{T}{(\tau_{att}^2)^{(k)}}\right) - \mu_{att}^{(k)}\left(\frac{\sum_{t=1}^T att_{t,k}}{(\tau_{att}^2)^{(k)}}\right)\right]$$

Riconosciamo il kernel di una normale univariata con determinati parametri: abbiamo perciò in questo caso una full conditional in forma chiusa da cui poter campionare e ciò corrisponderà all'utilizzo di un Gibbs-Sampler nell'MCMC.

$$\implies \mu_{att}^{(k)} \mid \dots \sim N\left(\left(\frac{1}{\sigma^2} + \frac{T}{(\tau_{att}^2)^{(k)}}\right)^{-1} \left(\frac{\sum_{t=1}^T att_{t,k}}{(\tau_{att}^2)^{(k)}}\right), \left(\frac{1}{\sigma^2} + \frac{T}{(\tau_{att}^2)^{(k)}}\right)^{-1}\right)$$

- $\mu_{def}^{(k)} \mid \dots$

Anche in questo caso non è necessario ripetere i calcoli, infatti possiamo sfruttare le asimmetria del problema e dedurre direttamente che: $\mu_{def}^{(k)} \mid \dots \sim N\left(\left(\frac{1}{\sigma^2} + \frac{T}{(\tau_{def}^2)^{(k)}}\right)^{-1} \left(\frac{\sum_{t=1}^T def_{t,k}}{(\tau_{def}^2)^{(k)}}\right), \left(\frac{1}{\sigma^2} + \frac{T}{(\tau_{def}^2)^{(k)}}\right)^{-1}\right)$

- $(\tau_{att}^2)^{(k)} \mid \dots$

$$\begin{aligned}
& f((\tau_{att}^2)^{(k)} \mid \dots) \propto f(\mathbf{y}, \mathbf{z}, \theta) \\
& \propto IG((\tau_{att}^2)^{(k)} \mid a, b) \times \prod_{t=1}^T N(att_{t,k} \mid \mu_{att}^{(k)}, (\tau_{att}^2)^{(k)}) \\
& \propto [(\tau_{att}^2)^{(k)}]^{-a-1} \exp(-b/(\tau_{att}^2)^{(k)}) \times [(\tau_{att}^2)^{(k)}]^{-T/2} \exp(-\sum_{t=1}^T \frac{(att_{t,k} - \mu_{att}^{(k)})^2}{2(\tau_{att}^2)^{(k)}}) \\
& \propto [(\tau_{att}^2)^{(k)}]^{-(a+T/2)-1} \exp[\frac{1}{(\tau_{att}^2)^{(k)}} (b + \frac{1}{2} \sum_{t=1}^T (att_{t,k} - \mu_{att}^{(k)})^2)]
\end{aligned}$$

Riconosciamo il kernel di un'inversa gamma con determinati parametri.

$$\Rightarrow (\tau_{att}^2)^{(k)} \mid \dots \sim IG(a + T/2, b + \frac{1}{2} \sum_{t=1}^T (att_{t,k} - \mu_{att}^{(k)})^2)$$

- $(\tau_{def}^2)^{(k)} \mid \dots$

Utilizziamo anche in questo caso la simmetria dei fattori di difesa e d'attacco.

$$\Rightarrow (\tau_{def}^2)^{(k)} \mid \dots \sim IG(a + T/2, b + \frac{1}{2} \sum_{t=1}^T (def_{t,k} - \mu_{def}^{(k)})^2)$$

- $P_{i,\cdot} \mid \dots$

Definiamo il numero di volte in cui si passa dallo stato i allo stato j all'interno di una stagione calcistica nel seguente modo:

$$n_{ij} := \sum_{t=1}^T \sum_{s=2}^{S_t} \mathbf{1}\{z_{t,s-1} = i, z_{t,s} = j\}$$

L'oggetto appena definito ci tornerà utile per determinare in forma chiusa la full conditional, in quanto essa è proporzionale alla produttoria (sugli stessi indici delle sommatorie con cui abbiamo definito n_{ij} di densità di variabili aleatorie del tipo "Discrete".

$$\begin{aligned}
& f(P_{i,\cdot} \mid \dots) \propto f(\mathbf{y}, \mathbf{z}, \theta) \\
& \propto \prod_{i=1}^2 Dir(P_{i,\cdot} \mid 1, 1) \times \prod_{t=1}^T [Disc(z_{t,1} \mid \pi) \prod_{s=2}^{S_t} Disc(z_{t,s} \mid P_{z_{t,s-1}, \cdot})] \\
& \propto \prod_{i=1}^2 P_{ij}^{1-1} \times \prod_{t=1}^T \prod_{s=2}^{S_t} \prod_{i=1}^2 P_{ij}^{\mathbf{1}\{z_{t,s-1}=i, z_{t,s}=j\}} \\
& \propto \prod_{i=1}^2 P_{ij}^{1-1} \times \prod_{i=1}^2 P_{ij}^{n_{ij}} = \prod_{i=1}^2 P_{ij}^{1+n_{ij}-1}
\end{aligned}$$

Riconosciamo il kernel di una Dirichlet con determinati parametri.

$$\Rightarrow P_{i,\cdot} \mid \dots \sim Dirichlet(1 + n_{i1}, 1 + n_{i2})$$

- $\pi \mid \dots$

Definiamo il numero di squadre che alla partita d'esordio sono nello stato k nel seguente modo:

$$m_k := \sum_{t=1}^T \mathbf{1}\{z_{t,1} = k\}$$

poichè, similmente a quanto visto precedentemente per $P_{i,\cdot}$, grazie ad m_k riusciremo a scrivere in forma chiusa la full conditional che stiamo cercando.

$$\begin{aligned}
& f(\pi \mid \dots) \propto f(\mathbf{y}, \mathbf{z}, \theta) \\
& \propto \prod_{i=1}^2 Dir(\pi \mid 1, 1) \times \prod_{t=1}^T [Disc(z_{t,1} \mid \pi) \prod_{s=2}^{S_t} Disc(z_{t,s} \mid P_{z_{t,s-1}, \cdot})] \\
& \propto \prod_{i=1}^2 \pi^{1-1} \times \prod_{t=1}^T \prod_{i=1}^2 \pi^{\mathbf{1}\{z_{t,1}=i\}} = \prod_{i=1}^2 \pi^{1-1} \pi^{m_k} = \prod_{i=1}^2 \pi^{1+m_k-1}
\end{aligned}$$

Riconosciamo anche in questo caso il kernel di una Dirichlet con determinati parametri.

$$\Rightarrow \pi \mid \dots \sim Dirichlet(1 + m_1, 1 + m_2)$$

3.4 Analisi dei risultati dell'MCMC

Utilizzando le full conditional ricavate abbiamo implementato una funzione R che permette di eseguire l'algoritmo MCMC relativo al modello (M2), tale funzione ha bisogno di ricevere come input un dataset nel formato descritto al capitolo 1 dell'elaborato: non necessariamente deve contenere tutte le partite di una stagione poichè l'MCMC funziona anche se utilizziamo un sottoinsieme del dataset di partenza o un dataset incompleto, come ad esempio una stagione che non è ancora terminata.

I risultati che andremo ad analizzare sono stati ottenuti eseguendo il codice per un totale di 50000 iterazioni, burn-in pari a 10000 e parametro di thin uguale a 10, ottenendo 4000 campioni dal nostro modello.

Iniziamo analizzando i trace plots e i grafici di autocorrelazione dei parametri del modello per $K = 2$ stati del processo latente, dove:

- 1 = "in forma"
- 2 = "fuori forma"




Figura 6: Trace plots delle medie per attacco e difesa in entrambi gli stati




Figura 7: Trace plots delle varianze per attacco e difesa in entrambi gli stati

Le catene dei parametri non presentando trend particolari, si distribuiscono infatti attorno al valor medio seguendo una certa varianza, ciò suggerisce che il modello possa essere arrivato a convergenza. Inoltre i campioni risultano essere sin

da subito indipendenti per tutti i parametri, l'indipendenza tra campioni è leggermente più lenta per quanto riguarda i samples della varianza per l'attacco e la difesa nello stato "fuori forma" $(\sigma_{att}^2)^{(2)}$, $(\sigma_{def}^2)^{(2)}$, ma resta comunque una velocità del tutto accettabile, in quanto dopo circa 10 campioni l'acf diventa nulla.

Nota: una scelta implementativa per quanto riguarda l'MCMC è stata quella di non utilizzare per i campioni simulati tramite Metropolis una varianza adattiva, in quanto a seguito di alcune prove preliminari si è notato che le catene dei campioni e le acf erano pressoché le stesse, con la differenza che utilizzare un passo Metropolis adattivo rallentava parecchio il codice in quanto la maggior parte dei parametri non avevano una full conditional in forma chiusa.

Le stime ricavate per i parametri in questione sono le seguenti:

$$\mu_{att}^{(1)} = 0.096, \mu_{att}^{(2)} = 0.052, \mu_{def}^{(1)} = 0.021, \mu_{def}^{(2)} = 0.014,$$

$$(\sigma_{att}^2)^{(1)} = 0.072, (\sigma_{att}^2)^{(2)} = 0.153, (\sigma_{def}^2)^{(1)} = 0.047, (\sigma_{def}^2)^{(2)} = 0.105$$

Notiamo come le medie associate allo stato "in forma" siano più alte rispetto a quelle associate allo stato "fuori forma", mentre per le varianze avviene l'inverso, questo vuol dire che si ha maggiore persistenza in termini di performance quando si è "in forma", questo è esattamente in linea con quanto ci si potrebbe aspettare, soprattutto in un campionato come quello inglese in cui le squadre seguono tutte una preparazione fisica e degli allenamenti molto duri, ciò porta ad avere un campionato equilibrato e dunque supporre una media comune dalla quale poter generare i fattori rispettivamente d'attacco e difesa è un'ipotesi corretta, che modella in maniera verosimile la realtà.




Figura 8: Distribuzione e trace plot dell'effetto casa

Vediamo anche la distribuzione ed la catena dei campioni associati al "fattore casa", supposto identico per ogni squadra del campionato e non influenzato dallo stato di forma della squadra. Calcoliamo la stima per del parametro ed anche l'intervallo di credibilità al 95% in modo tale da verificare se effettivamente è presente o meno evidenza statistica per l'effetto casa:

$$\hat{home} = 0.224, IC(home) = [0.092, 0.351]$$

poiché $0 \notin IC(home)$ possiamo concludere che effettivamente è stato corretto supporre l'esistenza del fattore casa, in quanto è statisticamente significativo e dunque le squadre che giocano in casa hanno un piccolo vantaggio in termini di gol segnati, questa potrebbe essere una diretta conseguenza del fatto che quando si gioca in casa i tifosi della proprio team sono molto più numerosi rispetto a quando si gioca in trasferta.




Figura 9: Parametri d'attacco a confronto




Figura 10: Parametri di difesa a confronto

L'analisi dei parametri $att_{t,k}$, $def_{t,k}$ $t \in T$, $k \in \{1, 2\}$ in termini di catene dei parametri risulterebbe essere troppo dispersiva e soprattutto poco interpretabile, si è quindi deciso di rappresentare graficamente le stime (media campionaria) per i fattori di attacco e difesa di ogni squadra di Premier League in ciascuno dei due stati, mettendoli a confronto con un diagramma a barre. E' importante inoltre ricordare che i termini di attacco e difesa per una squadra devono essere interpretati come degli oggetti che mi dicono quanto una squadra attacca/difende bene *rispetto alla media del campionato*, questo poichè abbiamo imposto i vincoli di identificabilità $\sum_{t \in T} att_{t,k} = 0$, $\sum_{t \in T} def_{t,k} = 0$.

Come ci aspetta quando le squadre sono "in forma" le performance crescono sia per quanto riguarda l'attacco, sia per la difesa in quanto osserviamo nel grafico a barre dei valori d'attacco maggiori e valori di difesa minori (poichè la difesa si oppone all'attacco, più una squadra ha il fattore difesa negativo più vuol dire che difende bene).




Figura 11: Trace plots ed acf relativi al Manchester City

Infine vediamo nella Figura 6 a titolo esemplificativo le catene per i parametri di attacco e difesa in entrambi gli stati per una singola squadra, il Manchester City, per mostrare che anche in questo caso i trace plots suggeriscono una convergenza e le acf decrescono rapidamente a zero.




Figura 12: Matrice di transizione del processo latente

Passiamo adesso all'analisi della matrice di transizione stimata tramite i campioni dell'MCMC che ci da importanti informazioni, in quanto come è possibile apprezzare nella figura 7:

- Se una squadra è "in forma" alla partita successiva rimarrà "in forma" con probabilità 0.887
- Se una squadra è "in forma" alla partita successiva diventerà "fuori forma" con probabilità 0.113
- Se una squadra è "fuori forma" alla partita successiva rimarrà "fuori forma" con probabilità 0.534
- Se una squadra è "fuori forma" alla partita successiva diventerà "in forma" con probabilità 0.466

Ci aspettiamo quindi che quando una squadra è "in forma" tende a rimanerci per un periodo di tempo più lungo rispetto a quando essa non è in forma: a conferma di questo risultato nella tabella seguente vediamo la proporzione di tempo che ogni squadra trascorre in uno stato, piuttosto che in nell'altro.

Tabella 3: Proporzione di tempo in ogni stato per team

Team	In Forma	Fuori Forma
Manchester United	0.795	0.205
AFC Bournemouth	0.800	0.200
Everton	0.793	0.207
Leicester City	0.788	0.212
Chelsea	0.796	0.204
Norwich City	0.793	0.207
Arsenal	0.800	0.200
Newcastle United	0.789	0.211
Stoke City	0.786	0.214
West Bromwich Albion	0.795	0.205
Aston Villa	0.811	0.189
West Ham United	0.794	0.206
Southampton	0.785	0.215
Swansea City	0.792	0.208
Tottenham Hotspur	0.803	0.197
Watford	0.789	0.211
Sunderland	0.790	0.210
Crystal Palace	0.786	0.214
Manchester City	0.790	0.210
Liverpool	0.783	0.217

3.5 Ranking tramite modello 2

E' interessante far vedere anche in che modo possono essere utilizzati i parametri che abbiamo analizzato nella sezione precedente. Una prima idea è quella di creare una classifica tramite i fattori di attacco e difesa stimati per le squadre. In questo modo possiamo confrontare il ranking che otterremo con la classifica finale della stagione corrispondente al nostro dataset e verificare se sono più o meno simili.

Il parametro tramite il quale andremo a riordinare in senso decrescente le squadre è l'*Overall Score*, quantità che include i fattori di attacco e difesa associati ad entrambi gli stati e definita come segue: $Overall_score_t = (att_{t,1} - def_{t,1}) * prop_{in,t} + (att_{t,2} - def_{t,2}) * prop_{out,t}, \forall t \in T$

Tabella 4: Ranking dei team basati sulle prestazioni (Nuovi Dati) vs Classifica Reale 2015/16

Team	Attack (in)	Defense (in)	Attack (out)	Defense (out)	Overall Score	Pos vera	Diff
Tottenham Hotspur	0.2488	-0.2037	0.0642	-0.0683	0.3894	3	-2
Leicester City	0.2138	-0.1952	0.1665	-0.0663	0.3716	1	+1
Manchester City	0.2482	-0.1093	0.1833	-0.1044	0.3428	4	-1
Arsenal	0.2066	-0.1886	0.0394	-0.0886	0.3418	2	+2
Southampton	0.1096	-0.1274	0.0846	-0.0405	0.2130	6	-1
West Ham United	0.1983	0.0196	0.0978	-0.0303	0.1683	7	-1
Manchester United	-0.0180	-0.1937	-0.0297	-0.1360	0.1614	5	+2
Liverpool	0.1572	0.0116	0.0887	-0.0608	0.1464	8	0
Chelsea	0.1249	0.0255	0.0588	0.0228	0.0864	10	-1
Everton	0.1114	0.0547	0.0722	0.0220	0.0554	11	-1
Swansea City	-0.1287	0.0154	-0.0340	-0.0006	-0.1210	12	-1
Watford	-0.1577	-0.0138	-0.0843	-0.0071	-0.1299	13	-1
Sunderland	-0.0342	0.1124	-0.0165	0.1049	-0.1413	17	-4
Crystal Palace	-0.1903	-0.0068	-0.0452	-0.0026	-0.1533	15	-1
Stoke City	-0.1335	0.0471	-0.1120	0.0313	-0.1727	9	+6
West Bromwich Albion	-0.2418	-0.0383	-0.1723	0.0044	-0.1980	14	+2
AFC Bournemouth	-0.0522	0.1892	-0.0977	0.0843	-0.2296	16	+1
Newcastle United	-0.1148	0.1576	0.0106	0.1091	-0.2358	18	0
Norwich City	-0.1786	0.1679	-0.0788	0.1417	-0.3204	19	0
Aston Villa	-0.3690	0.2755	-0.1957	0.0850	-0.5757	20	0

Nota: "in" = in forma, "out" = non in forma

Osserviamo che il ranking prodotto associa con successo il Leicester City alla prima posizione e l'Aston Villa all'ultima posizione e ciò ha perfettamente senso perchè la squadra vincitrice del campionato fu proprio il Leicester City e l'Aston Villa fu la squadra che totalizzo meno punti in campionato. Le posizioni intermedie del nostro ranking di output tuttavia non sono così accurate, in quanto certe quadre vengono "scambiate" di posizione come Arsenal, Tottenham Hotspur e Manchester City che arrivarono in codesto ordine di classifica in campionato; tuttavia sembra che il ranking catturi abbastanza bene le "fasce" in cui le squadre sono arrivate in classifica come nel caso di Leicester City, Arsenal, Tottenham Hotspur e Manchester City che sono tutte quante arrivate nella zona di qualificazione alla champions league.

3.6 Predizione dei risultati

Dopo aver eseguito l'algoritmo MCMC sul modello (M2), si dispone di una collezione di M campioni approssimati dalla distribuzione a posteriori congiunta. L'obiettivo della presente sezione è descrivere in modo rigoroso il procedimento mediante il quale si costruisce la distribuzione predittiva per una nuova partita tra due squadre del campionato.

Si consideri una nuova partita g^* tra una squadra di casa h^* e una squadra ospite a^* . Si denoti con:

- y_{g^*1} : numero di gol segnati dalla squadra di casa nella nuova partita;
- y_{g^*2} : numero di gol segnati dalla squadra ospite nella nuova partita;
- s_{h^*} e s_{a^*} : gli indici rispettivamente della nuova partita nella sequenza cronologica della squadra di casa e della squadra ospite;
- S_{h^*} e S_{a^*} : il numero totale di partite giocate dalla squadra di casa e dalla squadra ospite nei dati osservati.

Dall'algoritmo MCMC si dispone di M campioni congiunti:

$$\left\{ \text{home}^{(m)}, \text{att}_{t,k}^{(m)}, \text{def}_{t,k}^{(m)}, P^{(m)}, \mathbf{z}^{(m)} \right\}_{m=1}^M,$$

dove $\mathbf{z}^{(m)} = \{z_{t,s}^{(m)}\}_{t \in T, s \in S_t}$ rappresenta l'intera sequenza degli stati latenti per tutte le squadre e tutte le partite osservate, nel campione m .

• Passo 1: Estrazione dello stato di forma nell'ultima partita

Per ogni squadra $t \in \{h^*, a^*\}$, si identificano gli stati di forma nelle rispettive ultime partite osservate nel dataset. Poiché il numero totale di partite giocate dalla squadra t è S_t , lo stato di forma nella partita $s = S_t$ (l'ultima partita) è dato da:

$$z_{t,S_t}^{(m)}, \quad \forall m = 1, 2, \dots, M.$$

In particolare, definiamo:

$$z_{h^*, \text{last}}^{(m)} := z_{h^*, S_{h^*}}^{(m)}, \quad z_{a^*, \text{last}}^{(m)} := z_{a^*, S_{a^*}}^{(m)}.$$

Questi valori rappresentano, per ogni campione m , lo stato di forma della squadra di casa e della squadra ospite nel loro ultimi incontro rispettivamente.

• Passo 2: Propagazione dello stato attraverso la matrice di transizione

Nel modello (M2), lo stato di forma della squadra t nella partita successiva evolve secondo una catena di Markov con matrice di transizione P . Specificamente, dato lo stato al tempo $s - 1$, lo stato al tempo s segue la distribuzione:

$$z_{t,s} \mid z_{t,s-1} \sim \text{Discrete} \left(P_{z_{t,s-1}, \cdot} \right),$$

dove $P_{i,j} = \mathbb{P}(z_{t,s} = j \mid z_{t,s-1} = i)$ è l'elemento della matrice P in posizione (i, j) .

Per la nuova partita, che rappresenta la partita successiva nel tempo per entrambe le squadre, si applica questa stessa dinamica. Per ogni campione m e per ogni squadra $t \in \{h^*, a^*\}$, si genera lo stato futuro estraendo da una distribuzione categorica:

$$z_{t,s_t^*}^{(m)} \sim \text{Discrete} \left(P_{z_{t,\text{last}}^{(m)}, \cdot}^{(m)} \right).$$

In pratica, per il campione m , si estrae un indice di stato $k \in \{1, 2\}$ con probabilità proporzionali alla riga $z_{t,\text{last}}^{(m)}$ della matrice $P^{(m)}$.

Questo procedimento fornisce:

$$z_{h^*, s_{h^*}^*}^{(m)} \quad \text{e} \quad z_{a^*, s_{a^*}^*}^{(m)},$$

che rappresentano gli stati predetti nella nuova partita per il campione m .

• Passo 3: Calcolo dei parametri per simulare dalle Poisson

Una volta determinati gli stati latenti nella nuova partita per il campione m , si calcolano i parametri della distribuzione Poisson per i gol delle due squadre. Secondo il modello (M2), i rates sono dati da:

$$\lambda_{g^*1}^{(m)} = \exp \left(\text{home}^{(m)} + \text{att}_{h^*, z_{h^*, s_{h^*}^*}^{(m)}}^{(m)} + \text{def}_{a^*, z_{a^*, s_{a^*}^*}^{(m)}}^{(m)} \right),$$

$$\lambda_{g^*2}^{(m)} = \exp \left(\text{att}_{a^*, z_{a^*}^{(m)}, s_{a^*}^*}^{(m)} + \text{def}_{h^*, z_{h^*}^{(m)}, s_{h^*}^*}^{(m)} \right).$$

dove

- $\text{home}^{(m)}$ è il fattore campo nel campione m ;
- $\text{att}_{h^*, z_{h^*}^{(m)}, s_{h^*}^*}^{(m)}$ è il fattore di attacco della squadra di casa nello stato $z_{h^*}^{(m)}, s_{h^*}^*$, nel campione m ;
- $\text{def}_{a^*, z_{a^*}^{(m)}, s_{a^*}^*}^{(m)}$ è il fattore di difesa della squadra ospite nello stato $z_{a^*}^{(m)}, s_{a^*}^*$, nel campione m ;

• **Passo 4: Generazione di campioni dalla distribuzione predittiva**

Per ogni campione m , dati i rates calcolati nel Passo 3, si generano i gol osservati dalla distribuzione Poisson:

$$y_{g^*1}^{(m)} \sim \text{Poisson} \left(\lambda_{g^*1}^{(m)} \right), \quad y_{g^*2}^{(m)} \sim \text{Poisson} \left(\lambda_{g^*2}^{(m)} \right).$$

Il risultato è una collezione di M coppie di gol:

$$\left\{ \left(y_{g^*1}^{(m)}, y_{g^*2}^{(m)} \right) \right\}_{m=1}^M.$$

per una partita che non si è ancora giocata; possiamo dunque utilizzare questi campioni provenienti dalla distribuzione predittiva per rispondere alla nostra domanda iniziale: quanto finirà la partita?

Il ragionamento appena descritto ci ha formalmente permesso di campionare dalla distribuzione predittiva seguente:

$$f(y_{g^*1}, y_{g^*2} \mid \mathbf{y}) = \int_{\mathbf{z}} \int_{\theta} f(y_{g^*1}, y_{g^*2} \mid \mathbf{z}, \theta) f(\mathbf{z}, \theta \mid \mathbf{y}) d\theta d\mathbf{z}$$

3.7 Elaborazione dei campioni predittivi

Utilizziamo adesso la collezione di campioni predittivi generati con l'algoritmo descritto precedentemente, per calcolare alcune statistiche rilevanti della distribuzione predittiva, che ci aiuteranno ad avvicinarci ad una risposta per la domanda iniziale dalla quale nasce questo elaborato. In particolare andremo ad approssimare tramite metodi Monte Carlo tutte le quantità di nostro interesse.

Iniziamo con lo stimare il valore atteso del numero di gol della squadra di casa e della squadra ospite che varranno rispettivamente:

$$E[y_{g^*1} \mid \mathbf{y}] \approx \frac{1}{M} \sum_{m=1}^M y_{g^*1}^{(m)}.$$

$$E[y_{g^*2} \mid \mathbf{y}] \approx \frac{1}{M} \sum_{m=1}^M y_{g^*2}^{(m)}.$$

Oltre che al numero medio di gol per ciascun team, siamo ovviamente interessati anche alle probabilità dei possibili risultati, le quali possono essere stimate contando il numero di campioni che soddisfano ciascuna condizione:

$$P(y_{g^*1} > y_{g^*2} \mid \mathbf{y}) = E[\mathbf{1}\{y_{g^*1}^{(m)} > y_{g^*2}^{(m)}\}] \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{y_{g^*1}^{(m)} > y_{g^*2}^{(m)}\},$$

$$P(y_{g^*1} = y_{g^*2} \mid \mathbf{y}) = E[\mathbf{1}\{y_{g^*1}^{(m)} = y_{g^*2}^{(m)}\}] \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{y_{g^*1}^{(m)} = y_{g^*2}^{(m)}\},$$

$$P(y_{g^*1} < y_{g^*2} \mid \mathbf{y}) = E[\mathbf{1}\{y_{g^*1}^{(m)} < y_{g^*2}^{(m)}\}] \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{y_{g^*1}^{(m)} < y_{g^*2}^{(m)}\}.$$

Avendo simulato i gol per la squadra ospite e la squadra di casa come due Poisson indipendenti abbiamo già a disposizione i campioni per la marginale, tramite i quali possiamo stimare per ogni valore $k \in \{0, 1, 2, \dots\}$, la probabilità di osservare esattamente k gol:

$$\mathbb{P}(y_{g^*i} = k \mid \mathbf{y}) \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{y_{g^*i}^{(m)} = k\}, \quad i = 1, 2$$

Infine possiamo associare una probabilità ad uno specifico risultato esatto della partita andando a lavorare sulla distribuzione congiunta dei gol.

$$P(y_{g^*1} = i, y_{g^*2} = j \mid \mathbf{y}) = E[\mathbf{1}\{y_{g^*1}^{(m)} = i, y_{g^*2}^{(m)} = j\}] \approx \frac{1}{M} \sum_{m=1}^M \mathbf{1}\{y_{g^*1}^{(m)} = i, y_{g^*2}^{(m)} = j\}.$$

Questa matrice di probabilità rappresenta le probabilità di tutti i possibili risultati finali della partita, e consente di identificare gli esiti più probabili.

3.8 Analisi della predizione della partita Arsenal VS Chelsea

Il ragionamento per simulare dalla distribuzione predittiva è stato implementato su R tramite una funzione "predict_match" che prende in input i campioni generati dall'MCMC del modello (M2) ed il nome della squadra di casa e della squadra ospite per le quali si vuole tentare di fare inferenza su una partita non presente nel dataset tra le due squadre.

Abbiamo scelto di cercare di predire una partita tra Arsenal (squadra di casa) e Chelsea (squadra ospite), la scelta di queste due squadre non è casuale, ma determinata dal fatto che il dataset da noi utilizzato per simulare fa riferimento alle sole partite del campionato inglese di Premier League della stagione 2015/2016 e in questa stessa stagione si è giocata una partita di coppa di lega (Community Shield) tra Arsenal e Chelsea. L'idea è quindi di utilizzare il risultato della finale di Community Shield giocata nella stagione 2015/2016 tra Arsenal e Chelsea per cercare di vedere se la nostra predizione è andata o meno nella direzione giusta, tenendo a mente che la partita in questione terminò 1-0.

Di seguito riportiamo in una tabella i risultati ottenuti eseguendo la funzione "predict_match" per Arsenal VS Chelsea:

Tabella 5

Parametro	Arsenal (Home)	Chelsea (Away)
Valore Atteso Gol (xG)	1.61	0.97
Probabilità Risultato Finale		
• Vittoria Arsenal	52.58%	
• Pareggio	25.07%	
• Vittoria Chelsea	22.35%	
Risultati Esatti Più Probabili	Gol Casa	Gol Ospiti
1. 12.50% di probabilità	1	0
2. 11.25% di probabilità	1	1
3. 9.23% di probabilità	2	1

Osserviamo come l'esito più probabile che il nostro modello ha predetto è effettivamente 1-0, assegnando a quest'ultimo una probabilità del 12.50%, un valore abbastanza basso ma determinato anche dal fatto che stiamo analizzando uno specifico risultato. Invece per quanto riguarda la probabilità di vittoria dell'Arsenal si associa una probabilità del 52.28% valore abbastanza significativo se vogliamo semplicemente rispondere alla domanda "l'Arsenal vincerà contro il Chelsea?".

4 Conclusioni

In questo elaborato abbiamo affrontato il problema della previsione dei risultati calcistici attraverso l'implementazione e il confronto di due modelli statistici bayesiani applicati alla Premier League 2015/16. L'analisi ha permesso di rispondere al quesito iniziale — "quanto finirà la partita?" — evidenziando come l'introduzione di complessità modellistica porti a una rappresentazione più fedele della realtà sportiva.

4.1 Evoluzione modellistica e Stato di Forma

Il confronto tra il **Modello 1 (Gerarchico statico)** e il **Modello 2 (Mistura con HMM)** ha mostrato i limiti di un approccio che considera le abilità delle squadre costanti nel tempo. L'introduzione di una variabile latente nel Modello 2 ha permesso di catturare la natura dinamica delle prestazioni sportive. In particolare, l'analisi della matrice di transizione stimata ha rivelato un'interessante inerzia nelle prestazioni: le squadre tendono a mantenere lo stato "in forma" con una probabilità molto elevata (0.887). Inoltre, le stime dei parametri hanno confermato che nello stato "fuori forma" le prestazioni non solo peggiorano in media, ma diventano anche più imprevedibili, come evidenziato dalla maggiore varianza registrata ($(\sigma_{att}^2)^{(2)} = 0.153$).

4.2 Il Fattore Casa

Un risultato robusto, emerso trasversalmente in entrambi i modelli, è la conferma statistica del vantaggio casalingo. Sebbene la stima puntuale si riduca passando dal Modello 1 ($home \approx 0.332$) al Modello 2 ($home \approx 0.224$), in entrambi i casi gli intervalli di

credibilità escludono lo zero. Questo conferma che giocare tra le mura amiche offre un vantaggio reale e quantificabile, indipendente dallo stato di forma momentaneo della squadra.

4.3 Capacità Predittiva e Ranking

La validità del Modello 2 è stata testata "sul campo" prevedendo l'esito della Community Shield tra Arsenal e Chelsea, una partita esterna al dataset di training. Il modello ha dimostrato ottime capacità predittive, indicando il risultato esatto **1-0** come l'esito più probabile (con una probabilità del 12.50%) e assegnando correttamente la vittoria all'Arsenal con una probabilità complessiva del 52.58%. Anche il ranking generato tramite l'*Overall Score* ha dimostrato la capacità del modello di identificare correttamente le gerarchie del campionato (individuando correttamente il Leicester City come vincitore e l'Aston Villa come ultimo classificato), pur con alcune fisiologiche discrepanze nelle posizioni intermedie dovute all'intrinseca aleatorietà dello sport.

4.4 Sviluppi Futuri

Nonostante i risultati incoraggianti, il lavoro lascia spazio a ulteriori miglioramenti. Il principale limite riscontrato è l'elevato costo computazionale dell'algoritmo MCMC per il Modello 2. Per sviluppi futuri, si potrebbe arricchire il modello includendo:

- **Variabili esogene:** l'integrazione di dati su infortuni, calciomercato o cambi di allenatore.
- **Matrici di transizione specifiche:** implementare matrici di transizione P_t diverse per ogni squadra, per distinguere tra squadre "costanti" e squadre "umoralì".
- **Player-based Model:** I fattori di attacco e difesa attuali (att_t, def_t) sono associati all'intera squadra e non variano in base alla formazione schierata. Un'evoluzione significativa consisterebbe nel costruire il parametro della squadra come somma dei contributi individuali dei giocatori scesi in campo. Questo permetterebbe al modello di reagire dinamicamente al turnover o all'assenza di giocatori chiave (es. l'infortunio del capocannoniere), affinando la predizione per la singola partita.

In conclusione, l'approccio bayesiano dinamico si è rivelato uno strumento potente e flessibile in grado di offrire una chiave di lettura statistica alle narrazioni tipiche del mondo del calcio, come i "momenti di forma" e il "fattore campo".

5 R scripts

5.1 Dove trovare il codice usato per le simulazioni?

Il codice da noi scritto per ottenere i campioni del modello 1 e del modello 2 sono disponibili alla seguente repository github:
https://github.com/DaniloButtu/football_statistical_model.git